

Học những gì hữu ích: Lựa chọn bối cảnh phù hợp với nhiệm vụ cho các nhiệm vụ tầm nhìn

Jingyu Guo^{1,2*} Tiểu vương Konuk^{1,2,3} Fredrik Strand³ Christos Matsoukas⁴
 Kevin Smith^{1,2}

1 Viện Công nghệ Hoàng gia KTH, Thụy Điển

2 Phòng thí nghiệm khoa học sự sống, Thụy Điển

3 Viện Karolinska, Thụy Điển


4 AstraZeneca, Thụy Điển

Tóm tắt

Con người thường giải quyết sự không chắc chắn về thị giác bằng cách so sánh một hình ảnh với các ví dụ có liên quan, nhưng ViT thiếu khả năng xác định những ví dụ nào sẽ cải thiện dự đoán của họ. Chúng tôi giới thiệu Lựa chọn bối cảnh phù hợp với nhiệm vụ (TACS), một khung công tác học cách chọn các ví dụ được ghép nối để thực sự cải thiện hiệu suất nhiệm vụ thay vì những ví dụ chỉ có vẻ giống nhau. TACS cùng đào tạo mạng chọn với mô hình nhiệm vụ thông qua sơ đồ tối ưu hóa kết hợp kết hợp giám sát dựa trên độ dốc và học tăng cường, biến việc truy xuất trở thành một phần của mục tiêu học tập. Bằng cách điều chỉnh lựa chọn phù hợp với phân thưởng nhiệm vụ, TACS cho phép các mô hình phân biệt đối xử khám phá những ví dụ theo ngữ cảnh nào thực sự hữu ích. Trên 18 bộ dữ liệu bao gồm nhận dạng chi tiết, phân loại hình ảnh y tế và phân đoạn hình ảnh y tế, TACS luôn hoạt động tốt hơn khả năng truy xuất dựa trên sự tương đồng, đặc biệt là trong các môi trường đầy thách thức hoặc hạn chế về dữ liệu.

1. Giới thiệu

Các mô hình ngôn ngữ lớn (LLM) đã phát triển thành các mô hình tổng quát đa phương thức, vượt trội trong nhiều nhiệm vụ: họ có thể suy luận qua các phương thức, khái niệm và lĩnh vực. Họ thậm chí có thể cải thiện câu trả lời của mình bằng cách đưa ra dự đoán dựa trên cơ sở thu thập thông tin bên ngoài có liên quan [24, 30, 52]. Khả năng này đã trở thành một đặc điểm nổi bật của trí thông minh tổng quát, với các công trình gần đây hiện đang đề xuất các phương pháp để tìm hiểu những gì cần truy xuất [3, 13]. Tuy nhiên, các mô hình chuyên gia hiện thiếu cơ chế kết hợp thông tin được truy xuất vào các quyết định của họ ngoại trừ một số phương pháp đa chế độ xem hoặc đa phiên bản dựa trên dữ liệu được xác định trước hoặc được ghép nối thủ công [2, 15, 17, 43]. Tuy nhiên, các kiến trúc như Vision Transformers (ViTs) tiếp tục thống trị các nhiệm vụ thị giác phân biệt đối xử như phân loại và phân đoạn [5, 44], đặc biệt là trong các lĩnh vực chuyên biệt như phân tích y tế [39]. Những gì còn lại chưa có-



Hình 1. Tổng quan về Lựa chọn bối cảnh phù hợp với nhiệm vụ (TACS). Với một hình ảnh truy vấn, TACS học cách chọn ví dụ có nhiều thông tin nhất từ nhóm ứng viên để tạo thành cặp đầu vào phù hợp với nhiệm vụ. *mạng bộ chọn* dự đoán ứng cử viên nào cung cấp bối cảnh hữu ích nhất cho *mạng tác vụ xuôi dòng*, (ví dụ: bộ phân loại hoặc bộ phân đoạn) hoạt động trên cặp đã chọn. Bằng cách học cách truy xuất các ví dụ hữu ích thay vì chỉ đơn thuần là các ví dụ tương tự, TACS cải thiện độ chính xác và độ tin cậy của quyết định, đặc biệt trong các trường hợp không rõ ràng.

plored là cách một mô hình chuyên nghiệp có thể học cách truy xuất bối cảnh trực quan giúp nó hoạt động tốt hơn. Điều này làm nổi bật một lỗ hổng quan trọng: chúng ta đã dạy các chuyên gia tổng quát của mình cách tìm thông tin họ cần, chứ không phải các chuyên gia của chúng ta. Việc thu hẹp khoảng cách này đặt ra một câu hỏi cơ bản: *liệu một mô hình tầm nhìn chuyên biệt có thể tìm hiểu những ví dụ ngữ cảnh nào cải thiện hiệu suất của chính nó nhiều nhất không?*

Các chuyên gia về con người như bác sĩ X quang sử dụng thông tin theo ngữ cảnh để cải thiện khả năng phán đoán trực quan. Ví dụ, khi phân biệt giữa các dấu hiệu lành tính và ác tính, bác sĩ X quang có thể không chỉ tham khảo các trường hợp tương tự trước đó mà còn tham khảo các trường hợp khác nhau để làm rõ ranh giới chẩn đoán. Tương tự như vậy, hệ thống nhận dạng hình ảnh có thể được hưởng lợi nhiều hơn từ việc ghép một hình ảnh đầu vào với một ví dụ bổ sung, *ví dụ*, một

*Corresponding author: Jingyu Guo <jingyug@kth.se>

điều đó cho thấy sự tương phản mang tính phân biệt đối xử hơn là lấy ra người hàng xóm gần nhất. Quan sát này cho thấy rằng việc học cách chọn các ví dụ hữu ích, thay vì chỉ các ví dụ tương tự, có thể mở ra một hình thức lý luận theo ngữ cảnh mới cho các mô hình phân biệt đối xử.

Tuy nhiên, các hệ thống thị giác hiện tại không có cơ chế xác định thông tin theo ngữ cảnh nào thực sự sẽ cải thiện dự đoán của chúng. Một số phương pháp kết hợp đầu vào phụ trợ dựa vào phương pháp phỏng đoán cố định, ví dụ., sự tương đồng về hình ảnh, thành viên lớp hoặc khoảng cách không gian, thay vì tìm hiểu những ví dụ nào thực sự hữu ích cho nhiệm vụ. Sự thành công của thể hệ tăng cường truy xuất (RAG) trong các mô hình ngôn ngữ [24, 30] đã truyền cảm hứng cho một nhóm phương pháp tiếp cận học tập tăng cường truy xuất (RAL) rộng hơn [4, 11, 18, 31, 50, 52], trong đó các mô hình truy xuất thông tin bên ngoài để cải thiện lý luận và dự đoán trong các hệ thống tổng quát. Tuy nhiên, đối với các mô hình chuyên biệt về nhận dạng hình ảnh như ViT, việc truy xuất vẫn là bước tiền xử lý tĩnh: thiếu cơ chế xử lý bối cảnh động bên ngoài, chúng dựa vào các số liệu tương tự được tính toán trước hoặc các phần nhúng như CLIP hoặc DINO [32, 36, 51], ngầm giả định rằng sự tương đồng về nhận thức tương đương với tính hữu ích. Giả định này còn gây tranh cãi, vì chỉ sự giống nhau về mặt hình ảnh không đảm bảo rằng một ví dụ sẽ giúp ViT đưa ra quyết định tốt hơn.

Chúng tôi đề xuất LRA chọn bối cảnh phù hợp với nhiệm vụ (TACS), một khuôn khổ cho phép các mô hình trực quan có tính phân biệt đối xử tìm hiểu những gì hữu ích. TACS chuyển đổi lựa chọn ngữ cảnh từ một hoạt động tĩnh, được xác định trước thành một thành phần có thể học được, phù hợp với nhiệm vụ của quy trình trực quan. Nó bao gồm hai mô-đun được tối ưu hóa chung: một *mạng bộ chọn*, học cách xác định các ví dụ theo ngữ cảnh mang lại nhiều thông tin nhất và một *mạng xuôi dòng*, thực hiện nhiệm vụ thị giác chính bằng cách sử dụng cả đầu vào và ngữ cảnh đã chọn (Hình 1). Bộ chọn được huấn luyện bằng sơ đồ tối ưu hóa kết hợp kết hợp học tập dựa trên độ dốc thông qua việc thư giãn khác biệt với học tập tăng cường cho lựa chọn rời rạc, cho phép nó nhận phản hồi trực tiếp từ mục tiêu phía dưới và điều chỉnh lựa chọn với hiệu suất nhiệm vụ.

TACS cho phép các mô hình phân biệt đối xử như ViT tìm hiểu thông tin theo ngữ cảnh nào cải thiện dự đoán của chúng, đưa ra khả năng truy xuất phù hợp với nhiệm vụ cho các kiến trúc chỉ có tầm nhìn. Điều này đặc biệt có giá trị trong các lĩnh vực hạn chế về dữ liệu như hình ảnh y tế, nơi khan hiếm dữ liệu và chú thích theo cặp. Đóng góp của chúng tôi như sau:

1. Lựa chọn bối cảnh phù hợp với nhiệm vụ cho ViT. Chúng tôi giới thiệu LRA chọn bối cảnh phù hợp với nhiệm vụ, một khung cho phép các mô hình chỉ có tầm nhìn tìm hiểu các mẫu phụ trợ nào cải thiện hiệu suất ở khâu tiếp theo.
2. Chiến lược tối ưu hóa kết hợp. Chúng tôi phát triển một phương pháp đào tạo kết hợp học tập dựa trên độ dốc thông qua việc thư giãn khác biệt với học tập tăng cường để lựa chọn rời rạc, cho phép mạng chọn lọc

điều chỉnh trực tiếp các lựa chọn của nó với các tín hiệu hiệu suất xuôi dòng (ví dụ.: mất entropy chéo).

3. Xác nhận thực nghiệm toàn diện. Chúng tôi đánh giá TACS trên 18 bộ dữ liệu bao gồm phân loại hình ảnh tự nhiên chi tiết, phân loại và phân đoạn hình ảnh y tế, cho thấy những cải tiến nhất quán, đặc biệt là trong các cài đặt đầy thách thức hoặc hạn chế về dữ liệu.

2. Công việc liên quan

Công việc liên quan trước đây bao gồm hai lĩnh vực chính: học tập tăng cường truy xuất trong thị giác máy tính và các chiến lược tối ưu hóa để lấy mẫu có thể học được và lựa chọn rời rạc.

Học tập tăng cường truy xuất trong tầm nhìn

Học tập tăng cường truy xuất nâng cao hiệu suất của mô hình bằng cách điều chỉnh các dự đoán về thông tin bên ngoài được truy xuất từ tập hợp lớn. Nó bắt nguồn từ việc xử lý ngôn ngữ tự nhiên thông qua thể hệ tăng cường truy xuất (RAG), trong đó các mô hình ngôn ngữ truy xuất và điều kiện hóa văn bản có liên quan để giải quyết các nhiệm vụ dựa trên kiến thức [3, 13, 16, 20, 24, 30, 45]. Kể từ đó, ý tưởng này đã mở rộng sang lý luận đa phương thức [11, 18, 31, 50], tích hợp bằng chứng trực quan và văn bản cũng như các hệ thống chỉ có tầm nhìn [4, 36, 51] nhằm nâng cao khả năng nhận biết hoặc căn cứ bằng cách tham chiếu các hình ảnh được truy xuất.

Trong các khung này, việc truy xuất thường được coi là một biến tiềm ẩn [24, 31] và các mô hình được đào tạo để xác định các phần nhúng hỗ trợ tốt nhất cho mục tiêu tạo hoặc lý luận. Cách tiếp cận này đã được chứng minh là có hiệu quả đối với các mô hình tổng quát lớn có thể điều chỉnh linh hoạt dựa trên bối cảnh được truy xuất. Trong thị giác máy tính, các phương pháp tăng cường truy xuất đã được khám phá để nhận dạng đuôi dài [36], khái quát hóa miền [34, 35] và học vài lần [35, 51]. REACT [34] và SWAT [35] điều chỉnh các mô hình ngôn ngữ thị giác trên dữ liệu web được truy xuất, cho thấy rằng việc truy xuất có thể cải thiện việc truyền tải khi có sẵn các ví dụ liên quan. Tuy nhiên, trong cả hai khung, việc truy xuất là tĩnh và dựa trên sự tương đồng: hình ảnh được truy xuất được chọn từ các phần nhúng CLIP hoặc VLM và chỉ được sử dụng làm dữ liệu đào tạo bổ sung. Nói rộng hơn, việc truy xuất trong các mô hình thị giác phân biệt đối xử vẫn là một bước tiền xử lý tĩnh, dựa trên các số liệu tương tự được tính toán trước hoặc các phần nhúng cố định (ví dụ.: CLIP hoặc DINO) [32, 36, 51] và ngầm giả định rằng độ tương tự về nhận thức có tương quan với tính hữu ích của nhiệm vụ. Không giống như các hệ thống tổng quát kết hợp linh hoạt bối cảnh bên ngoài tùy ý, các kiến trúc phân biệt đối xử như ViT được đào tạo trên các đầu vào một chế độ xem cố định và thiếu cơ chế tích hợp linh hoạt các ví dụ được truy xuất. Ngược lại, TACS xác định lại việc truy xuất như một phần của chính quá trình suy luận, tìm hiểu chính sách lựa chọn phù hợp với từng trường hợp, nhiệm vụ nhằm tối ưu hóa hiệu suất xuôi dòng thay vì tương tự.

Lựa chọn dựa trên sự khác biệt và tăng cường

Việc truy xuất vốn dĩ bao gồm những lựa chọn rời rạc, đặt ra nhiều thách thức

lenges để tối ưu hóa từ đầu đến cuối. Để giải quyết vấn đề này, công việc trước đây đã khám phá các phương pháp thư giãn có thể khác biệt hoặc đào tạo dựa trên sự củng cố cho phép độ dốc định hình các chính sách phục hồi. Các phép tính gần đúng có thể phân biệt được bao gồm chung cất sự chú ý [20], chung cất sự bối rối [21] và phản ứng tổng hợp có chủ ý [18], truyền bá độ dốc nhiệm vụ thông qua các trọng số truy xuất. Các chiến lược dựa trên sự củng cố bổ sung sẽ tối ưu hóa rõ ràng việc truy xuất bằng cách sử dụng các phần thưởng phụ thuộc vào nhiệm vụ [3, 13, 31, 42]. SmartRAG [13] và RAG-DDR [31] đã giới thiệu các phần thưởng dữ liệu khác nhau để cùng đào tạo các mô-đun truy xuất và tạo, trong khi DRO [42] coi việc truy xuất là lấy mẫu tầm quan trọng đối với các hoán vị tiềm ẩn, sử dụng học tăng cường dựa trên chính sách để tối đa hóa hiệu suất nhiệm vụ mong đợi. Những công trình này cho thấy chất lượng truy xuất được cải thiện khi việc lựa chọn được định hình bởi các kết quả tiếp theo thay vì các số liệu tĩnh.

Tuy nhiên, các phương pháp truy xuất dựa trên sự tăng cường và khác biệt hiện có nhắm vào các nhiệm vụ tổng hợp hoặc đa phương thức. Chúng chưa được áp dụng cho các cài đặt hình ảnh mang tính phân biệt, trong đó giá trị của bối cảnh được truy xuất phải được đo lường bằng sự đóng góp của nó vào độ chính xác dự đoán thay vì tính trôi chảy hoặc mạch lạc của văn bản. Cách tiếp cận của chúng tôi mở rộng nguyên tắc này sang nhận dạng trực quan: chúng tôi giới thiệu một khung kết hợp việc học những đặc trưng trên độ dốc với tối ưu hóa độ dốc chính sách bằng cách sử dụng tín hiệu phần thưởng xuôi dòng. Công thức này cho phép lựa chọn bối cảnh có thể học được, phù hợp với nhiệm vụ đối với các kiến trúc phân biệt đối xử như ViT, một khả năng không được giải quyết bằng các phương pháp tăng cường truy xuất trước đó.

3. Phương pháp

Chúng tôi đề xuất TACS, một khuôn khổ cho phép các mô hình tầm nhìn phân biệt tìm hiểu những ví dụ theo ngữ cảnh nào cải thiện dự đoán của chúng nhiều nhất. *Bộ chọn* truy xuất các mẫu thông tin từ nhóm ứng viên và được đào tạo cùng với *Mạng tác vụ hạ nguồn* (ví dụ: bộ phân loại hoặc bộ phân đoạn), khiến việc truy xuất trở thành một phần của mục tiêu học tập.

Theo trực giác, Bộ chọn tìm hiểu khái niệm về *tính hữu ích*: mức tăng dự kiến trong hiệu suất nhiệm vụ xuôi dòng nếu một ứng cử viên được truy xuất được ghép nối với truy vấn. Nhưng việc truy xuất vốn đã rời rạc, gây khó khăn cho việc tối ưu hóa từ đầu đến cuối. Chúng tôi giải quyết vấn đề này bằng chiến lược tối ưu hóa kết hợp kết hợp hai tín hiệu bổ sung: (1) *đường lấy mẫu khác biệt* cung cấp luồng gradient ổn định và mô hình hóa các mối quan hệ tiện ích xuôi dòng giữa các ứng viên và (2) *đường dẫn tối ưu hóa chính sách* tinh chỉnh lựa chọn thông qua phản hồi dựa trên phần thưởng từ nhiệm vụ xuôi dòng, được đào tạo chung như minh họa trong Hình 2.

3.1. Ngành kiến trúc

Cho một hình ảnh truy vấn $x_q \in \mathbb{R}^{H \times W \times C}$ và một nhóm N_c ứng viên $\{x_c^i\}_{i=1}^{N_c}$, trực chọn Selector mã hóa chúng thành z_q và $z_c^i \in \mathbb{R}^{(L+1) \times D}$ trong đó L biểu thị số lượng

mã thông báo không gian và D là kích thước đối tượng. *Điểm tiện ích* của mỗi ứng viên được tính như sau

$$s_c^i = z_q^T z_c^i, \quad (1)$$

và chuyển đổi thành xác suất lựa chọn

$$p(x_c^i | x_q) = \frac{\exp(s_c^i)}{\sum_{j=1}^{N_c} \exp(s_c^j)}. \quad (2)$$

Trong quá trình suy luận, bối cảnh được chọn là

$$x_{\text{sel}} = \arg \max_i p(x_c^i | x_q). \quad (3)$$

Mạng tác vụ hạ nguồn f_d dự đoán $\hat{y} = f_d(x_q, x_{\text{sel}})$ và độ dốc của nó cung cấp phản hồi cho Bộ chọn thông qua cả hai đường dẫn tối ưu hóa (Phần 3.2). Khóa đào tạo chung này khuyến khích các nội dung nhúng phản ánh *tiện ích của nhiệm vụ* thay vì sự tương đồng về mặt hình ảnh, chuyển đổi việc truy xuất từ bước tiền xử lý tĩnh thành một thành phần có thể học được của một quy trình phân biệt đối xử.

3.2. Học cách lựa chọn thông qua tối ưu hóa kết hợp

Việc huấn luyện Bộ chọn bao gồm các lựa chọn truy xuất rời rạc, ngăn cản việc truyền gradient trực tiếp. Để làm cho việc truy xuất có thể học được, chúng tôi sử dụng chiến lược tối ưu hóa kết hợp kết hợp việc nói lòng có thể phân biệt được với sự củng cố dựa trên chính sách. Đường dẫn khác biệt cung cấp dòng chuyển đổi ổn định và định hình các mối quan hệ tiện ích xuôi dòng giữa các ứng viên, trong khi đường dẫn chính sách củng cố các hành vi lựa chọn riêng biệt thực sự cải thiện hiệu suất ở cấp dưới.

Đường dẫn lấy mẫu khác biệt Để kích hoạt luồng chuyển đổi từ đầu đến cuối, chúng tôi áp dụng công cụ ước tính Gumbel-Softmax xuyên suốt [22], một phép tính gần đúng có thể phân biệt được đối với việc lấy mẫu phân loại. Điều này cho phép Bộ chọn tạo ra các lựa chọn nhanh trong quá trình chuyển tiếp trong khi vẫn duy trì độ dốc trong quá trình truyền ngược. Phân phối Gumbel-Softmax cung cấp sự thoải mái liên tục cho phân phối phân loại bằng cách thêm nhiễu Gumbel vào logits:

$$g_i = -\log(-\log(u_i)), \quad u_i \sim \mathcal{U}(0, 1) \quad (4)$$


Mẫu mềm sau đó được tính toán bằng cách sử dụng softmax được kiểm soát nhiệt độ thay vì phương trình. (2):

$$p(x_c^i | x_q) = \frac{\exp((s_c^i + g_i)/\tau)}{\sum_{j=1}^{N_c} \exp((s_c^j + g_j)/\tau)} \quad (5)$$

Chúng tôi áp dụng trực tiếp thông qua ước tính trên

$p(x_c^i | x_q)$ cho lựa chọn phân loại theo [22], để duy trì độ ổn định độ dốc và độ sắc nét của lựa chọn. Mục tiêu tương ứng cho nhiệm vụ xuôi dòng là

$$\mathcal{L}_{\text{grad}} = \mathcal{L}_{\text{ce}}(f_d(x_q, x_{\text{sel}}), y), \quad (6)$$



Hình 2. Quy trình kiến trúc và đào tạo của Lựa chọn bối cảnh phù hợp với nhiệm vụ (TACS). (a) Bộ chọn xử lý hình ảnh truy vấn x_q và nhóm ứng viên x_c^i và chọn mẫu hữu ích nhất. Trong quá trình đào tạo, việc lựa chọn được tối ưu hóa thông qua hai đường dẫn tối ưu hóa bổ sung (b). Đường dẫn Lấy mẫu khác biệt (màu xanh lam) sử dụng quá trình tham số lại Gumbel-Softmax xuyên suốt trên các điểm tiện ích s_c để triển khai lựa chọn ứng viên theo phân loại, cho phép luồng chuyển màu từ đầu đến cuối thông qua việc mất nhiệm vụ $\mathcal{L}_{grad}$. Đường dẫn chính sách (màu đỏ) lấy mẫu một hành động riêng biệt dựa trên s_c và cập nhật Bộ chọn bằng cách sử dụng các dải màu chính sách với phần thưởng phù hợp với nhiệm vụ $r(o, a)$ bắt nguồn từ hiệu suất xuôi dòng. Các cặp độ và phần thưởng cùng nhau cập nhật các tham số Bộ chọn được chia sẻ. (c–d) Ví dụ về các nhiệm vụ tiếp theo: phân loại và phân đoạn. Sự mất mát kết hợp cho phép lựa chọn phù hợp với nhiệm vụ ổn định nhưng mang tính quyết định.

trong đó $\mathcal{L}_{ce}$ là mất nhiệm vụ.

Đường dẫn tối ưu hóa chính sách dựa trên phần thưởng. Mặc dù lấy mẫu khác biệt giúp ổn định quá trình đào tạo nhưng nó không đánh giá rõ ràng liệu việc thêm hình ảnh được truy xuất có thực sự cải thiện dự đoán tiếp theo hay không. Lý tưởng nhất, một lựa chọn tốt phải đáp ứng:

$$\mathcal{L}_{ce}(f_d(x_q, x_c), y) < \mathcal{L}_{ce}(f_d(x_q, \emptyset), y), \quad (7)$$

chỉ ra rằng ngữ cảnh được truy xuất mang lại mức độ mất nhiệm vụ thấp hơn so với việc chỉ sử dụng truy vấn. Để nắm bắt được sự cải thiện tương đối này, chúng tôi tối ưu hóa Bộ chọn làm chính sách nhận phản hồi khen thưởng từ mô hình hạ nguồn. Trong con đường này, Selector đóng vai trò như một tác nhân với các quan sát $o = \{z_q, z_c^1, \dots, z_c^{N_c}\}$, hành động $a \in \{1, \dots, N_c\}$ và một chính sách $\pi(a|o) = \text{softmax}(s(o))$ được tham số hóa theo điểm tiện ích. Phần thưởng đo lường sự cải thiện hiệu suất ở khâu tiếp theo:

$$r(o, a) = \mathcal{L}_{ce}(f_d(x_q, \emptyset), y) - \mathcal{L}_{ce}(f_d(x_q, x_c^a), y), \quad (8)$$

trong đó phần thưởng tích cực chỉ ra rằng hình ảnh được truy xuất cải thiện độ chính xác của nhiệm vụ. Các gradient được tách ra khỏi Nhiệm vụ

mô hình sao cho việc cập nhật chính sách chỉ phụ thuộc vào các tín hiệu khen thưởng. Khi đó mục tiêu chính sách được xác định là:

$$\mathcal{L}_{policy} = -\mathbb{E}_{a \sim \pi(\cdot|o)}[\log \pi(a|o) A(o, a)], \quad (9)$$

trong đó $A(o, a)$ biểu thị hàm lợi thế, được tính là phần thưởng được tiêu chuẩn hóa trong mỗi đợt để giảm chênh lệch độ dốc và ổn định cập nhật.

Mục tiêu chung. Cả hai đường dẫn tối ưu hóa đều chia sẻ các tham số Bộ chọn và được đào tạo chung, đảm bảo rằng độ dốc và phần thưởng ảnh hưởng đến khái niệm chung về tiện ích nhiệm vụ. Tồn thất đào tạo tổng thể kết hợp cả hai thành phần:

$$\mathcal{L}_{TACS} = \mathcal{L}_{grad} + \lambda \mathcal{L}_{policy}, \quad (10)$$

trong đó λ cân bằng các cập nhật dựa trên độ dốc và dựa trên phần thưởng.

4. Thí nghiệm

Chúng tôi đánh giá Lựa chọn bối cảnh phù hợp với nhiệm vụ được đề xuất trên các nhiệm vụ nhận dạng hình ảnh đa dạng để kiểm tra ba giả thuyết: (1) TACS khái quát hóa các nhiệm vụ và lĩnh vực, bao gồm hình ảnh tự nhiên và y tế; (2) lợi ích của nó phát sinh từ việc lựa chọn phù hợp với nhiệm vụ học tập; và (3) chính sách lựa chọn đã học nắm bắt các mối quan hệ theo ngữ cảnh có thể giải thích được, khác với việc truy xuất dựa trên sự tương đồng thông thường.

Bảng 1. Tóm tắt các bộ dữ liệu được sử dụng trong đánh giá. Các bộ dữ liệu được chọn trải rộng trên các lĩnh vực trực quan và cấp độ giám sát khác nhau để kiểm tra tính khái quát và độ chắc chắn.

Domain	Task	#Datasets	Example Benchmarks
Natural	Fine-grained classification	11	CUB, Cars, SUN397, ...
Medical	Classification	4	DDSM, ISIC, APTOS, ...
Medical	Segmentation	3	ISIC-2017, Kvasir, DRIVE

4.1. Bộ dữ liệu và nhiệm vụ

Để đánh giá tính tổng quát, chúng tôi đánh giá TACS trên 18 bộ dữ liệu bao gồm hình ảnh tự nhiên và y tế. Chúng được chọn để thể hiện những thách thức bổ sung: các bài kiểm tra nhận dạng chi tiết kiểm tra các ranh giới tinh vi giữa các lớp, phân loại y tế thăm dò tính chắc chắn trong bối cảnh chẩn đoán mơ hồ và khan hiếm dữ liệu, và phân đoạn y tế đánh giá lý luận có cấu trúc dưới sự giám sát hạn chế (Bảng 1).

Phân loại hình ảnh tự nhiên chi tiết. Chúng tôi sử dụng 11 điểm chuẩn bao gồm Máy bay [38], Caltech-101 [12], Caltech-256 [14], CIFAR-10 [28], CIFAR-100 [28], CUB [48], DTD [8], Food-101 [6], Oxford Pets [40], Stanford Cars [27] và SUN397 [49]. Các bộ dữ liệu này có phạm vi từ 5, 000 đến 110, 000 hình ảnh và nhấn mạnh các biến thể bề ngoài tinh tế và tính đa dạng lớn trong nội bộ lớp, một cài đặt lý tưởng để đánh giá xem việc ghép nối theo ngữ cảnh đã học có nâng cao khả năng phân biệt hay không.

Phân loại hình ảnh y tế Chúng tôi bao gồm bốn bộ dữ liệu từ hình ảnh vú (DDSM [29]), da (ISIC-2019 [9, 10, 47]), ung thư đại trực tràng (Col. [26]) và hình ảnh võng mạc (APTOS2019 [25]). Chúng có kích thước mẫu nhỏ và chữ ký trực quan chồng chéo, trong đó các ví dụ ngữ cảnh hữu ích có thể bù đắp cho sự giám sát hạn chế.

Phân đoạn y tế. Chúng tôi tiếp tục thử nghiệm ISIC-2017 [9], Kvasir-SEG [23] và DRIVE [46] để kiểm tra xem TACS có thể hỗ trợ dự đoán cấp pixel hay không. Các nhiệm vụ này đánh giá xem việc truy xuất phù hợp với nhiệm vụ có hỗ trợ lý luận không gian và phân định ranh giới rõ ràng hay không.

Các thước đo đánh giá. Hiệu suất được báo cáo bằng cách sử dụng tiêu chuẩn số liệu cho từng nhiệm vụ: Để phân loại chi tiết, chúng tôi tuân theo [7] và báo cáo độ chính xác hàng đầu hoặc độ chính xác trung bình cho mỗi lớp cho mỗi tập dữ liệu. Đối với các nhiệm vụ phân loại y tế, chúng tôi báo cáo Kappa bậc hai của Cohen cho APTOS2019, độ chính xác cho Đại trực tràng, ROC-AUC cho DDSM và Thu hồi trên ISIC 2019, sau đây [19]. Đối với phân khúc y tế, chúng tôi báo cáo hệ số Dice và IoU.

4.2. Chi tiết triển khai

Bộ chọn và Mạng tác vụ xuôi dòng có chung đường trục ViT-S/16. Tất cả các mô hình đều được khởi tạo với trọng lượng được huấn luyện trước DINOv3 [44] và được tinh chỉnh bằng AdamW opti-

máy đo [37]. Việc triển khai mô hình đa đầu vào xuôi dòng thay đổi tùy theo nhiệm vụ. Để phân loại, chúng tôi chỉ cần ghép các phần nhúng bản vá của hình ảnh chính và hình ảnh được ghép nối trước khi gửi chúng đến các khối chuyển đổi và tinh chỉnh toàn bộ mô hình; Để phân đoạn, chúng tôi đồng bằng xương sống được huấn luyện trước và gắn khối chú ý chéo có kiểm soát [1, 33] vào mỗi khối biến áp, để nâng cao các tính năng hình ảnh chính và sử dụng đầu DPT nhẹ [41] để có được phân đoạn cuối cùng. Chúng tôi đặt nhiệt độ Gumbel-Softmax $\tau = 0.1$ và trọng lượng lại $\lambda = 1.0$ theo mặc định. Quá trình đào tạo sử dụng 100 kỷ nguyên với lập kế hoạch tốc độ học tập $\cos$. Kích thước lô là 64 để phân loại và 8 để phân đoạn. Hình ảnh được thay đổi kích thước thành độ phân giải 256×256 và được tăng cường bằng các thao tác lật ngang và dọc cũng như cắt thay đổi kích thước ngẫu nhiên trong quá trình đào tạo. Tất cả các model đều được đào tạo trên một GPU NVIDIA A100 duy nhất. Mỗi tập dữ liệu tuân theo sự phân chia tiêu chuẩn của nó và kết quả được tính trung bình trên ba hạt giống ngẫu nhiên để đảm bảo độ tin cậy.

Xây dựng hồ bơi ứng cử viên. Đối với mỗi tập dữ liệu (ngoại trừ DRIVE do kích thước nhỏ), chúng tôi lấy mẫu 20% hình ảnh đào tạo để tạo thành nhóm ứng viên cố định được sử dụng trong quá trình đào tạo và đánh giá. Các hình ảnh liên quan đến truy vấn (ví dụ: từ cùng một bệnh nhân) được loại trừ trong tất cả các thao tác ghép nối để tránh rò rỉ dữ liệu.

4.3. Đường cơ sở

Chúng tôi thiết kế các đường cơ sở để dần dần tách biệt tác động của việc truy xuất phù hợp với nhiệm vụ, từ không truy xuất đến lựa chọn đã học đầy đủ:

- Không có ngữ cảnh: mô hình chỉ xử lý hình ảnh truy vấn mà không có bất kỳ đầu vào theo ngữ cảnh nào.
- Truy xuất ngữ cảnh ngẫu nhiên: một ứng cử viên ngẫu nhiên được ghép nối với mỗi truy vấn, thể hiện việc truy xuất mà không cần hướng dẫn.
- Truy xuất tính tương tự DINO đồng lạnh: truy xuất dựa trên các phần nhúng DINOv3 được tính toán trước [51]; con chó sẵn bị đóng băng và không thể học được.
- Ngữ cảnh tính năng trung bình: tập hợp mềm của phần trên- k đã truy xuất các tính năng thành một biểu diễn ngữ cảnh liên tục theo biểu thức. (2) (không gia cố).

4.4. Kết quả chính

Tab. 2 tóm tắt các kết quả trên các bộ dữ liệu phân loại y tế và chi tiết. Tab. 3 tóm tắt kết quả trên các tập dữ liệu phân đoạn. TACS luôn vượt trội hơn tất cả các đường cơ sở trên các lĩnh vực và nhiệm vụ, xác thực Giả thuyết 1 rằng Lựa chọn bối cảnh phù hợp với nhiệm vụ đã khái quát rộng rãi.

Phân loại chi tiết. Trên 11 tập dữ liệu, TACS cải thiện độ chính xác trung bình +1,7% so với đường cơ sở truy xuất cố định, với mức tăng lên tới +2,6% trên SUN397 và +3,8% trên CUB-200. Những cải tiến lớn nhất xảy ra trên SUN397 và CUB-200, các bộ dữ liệu được đặc trưng bởi

Bảng 2. Kết quả chính về điểm chuẩn phân loại hình ảnh chi tiết và y tế. Các kết quả tốt nhất được đánh dấu cho mỗi nhiệm vụ.

	Aircr. mAcc ↑	Cal101 mAcc ↑	Cal256 mAcc ↑	C10 Acc ↑	C100 Acc ↑	CUB Acc ↑	DTD Acc ↑	Food Acc ↑	Pets mAcc ↑	Cars Acc ↑	SUN Acc ↑	Avg. - ↑	APTOS F ↑	Col. Acc ↑	DDSM AUC ↑	ISIC Rec ↑	Avg. - ↑
No-Context	84.3	94.3	87.8	97.9	87.8	82.1	76.1	89.2	89.8	92.4	68.0	86.3	89.8	96.2	96.1	82.0	91.0
Random Context Ret.	82.8	94.2	86.3	97.6	87.6	82.1	74.6	89.3	90.0	92.3	69.0	86.0	89.8	96.8	96.3	83.5	91.6
Frozen DINO Similarity Ret.	85.1	94.7	87.3	97.8	88.4	81.4	75.4	89.9	90.3	93.0	69.2	86.6	90.4	97.0	96.1	84.5	92.0
Feature-Averaged Context.	85.3	94.3	87.4	97.8	88.6	82.6	76.3	90.5	90.7	93.2	66.7	86.7	90.2	97.5	96.6	84.2	92.1
TACS (Ours)	85.9	95.9	89.3	98.5	89.2	85.2	77.7	92.6	91.3	94.1	71.8	88.3	91.1	97.9	97.4	85.2	92.9

Bảng 3. Kết quả chính về tiêu chuẩn phân khúc y tế.

	DRIVE		ISIC 2017		Kvasir-SEG	
	Dice ↑	IoU ↑	Dice ↑	IoU ↑	Dice ↑	IoU ↑
No-Context	76.2	64.6	83.3	74.4	84.6	77.0
Random Context Ret.	76.7	64.9	83.7	76.3	85.6	79.9
Frozen DINO Similarity Ret.	77.5	64.8	84.4	76.0	86.3	80.0
Feature-Averaged Context	77.6	64.8	84.5	75.6	86.4	79.8
TACS (Ours)	78.1	65.4	85.0	76.5	87.1	81.1

tính đa dạng cao trong nội bộ lớp và ranh giới giữa các lớp tinh tế. Ở đây, việc truy xuất dựa trên sự tương đồng thường củng cố sự dư thừa bằng cách chọn những trường hợp gần trùng lặp (ví dụ:., những con chim có tư thế hoặc cảnh tương tự dưới ánh sáng giống nhau), trong khi TACS học cách truy xuất các ví dụ bổ sung thể hiện sự tương phản có tính phân biệt như tư thế, ánh sáng hoặc bố cục không gian khác nhau, giúp mô hình tinh chỉnh ranh giới quyết định của nó một cách chi tiết.

Phân loại y tế. Trong các nhiệm vụ phân loại y tế, TACS luôn vượt trội hơn tất cả các đường cơ sở, đạt mức tăng trung bình 0,9% so với truy xuất độ tương tự DINO. Mức tăng lớn nhất xảy ra trên DDSM, trong đó chính sách lựa chọn đã học cung cấp +1,3% cải thiện AUC.

Phân đoạn y tế. Trên DRIVE, ISIC-2017 và Kvasir-SEG, TACS liên tục cải thiện chất lượng phân đoạn trên tất cả các đường cơ sở, đạt được tới +1,1 IoU trên Kvasir-SEG. Những lợi ích này phản ánh khả năng của mô hình trong việc truy xuất các ví dụ mang tính thông tin theo ngữ cảnh mang lại lợi ích thực nghiệm cho các nhiệm vụ dự đoán dày đặc.

4.5. Nghiên cứu cắt bỏ

Để kiểm tra Giả thuyết 2 (H2), rằng mức tăng hiệu suất xuất phát từ việc truy xuất phù hợp với nhiệm vụ đã học, chúng tôi tiến hành các thử nghiệm cắt bỏ để tách biệt tác động của (a) ghép nối theo ngữ cảnh và (b) các thành phần tối ưu hóa kết hợp.

Tác dụng của việc ghép nối theo ngữ cảnh. Chúng tôi so sánh TACS với một số cài đặt điều khiển có chung kiến trúc nhưng khác nhau về cách ghép nối các hình ảnh theo ngữ cảnh. Cụ thể, chúng tôi thay thế việc truy xuất đã học bằng (i) không có hình ảnh ngữ cảnh, (ii) một hình ảnh trống, (iii) một bản sao của hình ảnh truy vấn, (iv) một phiên bản nhiễu của hình ảnh truy vấn và (v) truy xuất dựa trên độ tương tự tinh bằng cách sử dụng các phần nhúng DINOv3 cố định (như trong các kết quả chính). Kết quả xuất hiện trong Tab. 4. Trên cả bộ dữ liệu tự nhiên và y tế, những lựa chọn thay thế này tạo ra dữ liệu nhỏ hơn hoặc

lợi ích không nhất quán, chứng tỏ rằng những cải tiến không phát sinh từ việc ghép nhiều mã thông báo hình ảnh hơn hoặc chỉ từ dung lượng mô hình. Thay vào đó, hiệu suất sẽ tăng theo *tính thông tin* của hình ảnh được truy xuất. Việc cung cấp hình ảnh ngữ cảnh trống hoặc sao chép hình ảnh truy vấn dưới dạng hình ảnh ngữ cảnh có tác dụng tương tự như việc không cung cấp hình ảnh ngữ cảnh, làm giảm hiệu suất khoảng 2%. Việc truy xuất hình ảnh tương tự đã sửa lỗi cải thiện hiệu suất phần nào, nhưng kém hơn đáng kể so với TACS, trong đó các ví dụ được chứng minh bằng thực nghiệm là hữu ích hơn cho tác vụ tiếp theo.

Ảnh hưởng của các thành phần tối ưu hóa. Để đánh giá vai trò của từng thành phần tối ưu hóa, chúng tôi loại bỏ các mục tiêu dựa trên chính sách và có thể khác biệt của TACS. Chúng tôi thử nghiệm bốn biến thể: (a) một trình truy xuất cố định với các phần nhúng cố định, (b) chỉ lựa chọn mềm (có thể phân biệt), (c) chỉ lựa chọn cứng (dựa trên chính sách) và (d) mô hình đường dẫn kép đầy đủ. Kết quả trong Tab. 5 cho thấy rằng mặc dù mỗi đường dẫn cải thiện riêng lẻ so với truy xuất tĩnh, nhưng sự kết hợp của chúng mang lại hiệu suất ổn định nhất và cao nhất trên các tập dữ liệu. Đường dẫn lấy mẫu khác biệt cung cấp khả năng giám sát trơn tru trong quá trình đào tạo ban đầu, trong khi đường dẫn tối ưu hóa chính sách sẽ tinh chỉnh các quyết định lựa chọn riêng biệt nhằm tối đa hóa phần thưởng tiếp theo. Điều này khẳng định H2: hiệu suất đạt được bắt nguồn từ quá trình lựa chọn phù hợp với nhiệm vụ đã học được thúc đẩy bởi sự giám sát độ dốc mượt mà và phản hồi khen thưởng riêng biệt.

4.6. Phân tích và giải thích

Cuối cùng, chúng tôi điều tra Giả thuyết 3 (H3): rằng chính sách lựa chọn đã học nắm bắt được các mối quan hệ theo ngữ cảnh có thể giải thích được, khác biệt với việc truy xuất điểm tương đồng thông thường.


Phân tích hành vi lựa chọn Chúng tôi phân tích sự phân bố của các cặp được chọn qua ranh giới lớp và sự tương đồng về mặt hình ảnh. Hình 3 so sánh tốc độ chồng chéo lớp và khoảng cách LIPS giữa truy vấn và ví dụ được truy xuất về độ tương tự DINO và TACS. Trong khi các phương pháp dựa trên sự tương đồng áp đảo lựa chọn các đối tượng gần trùng lặp, TACS tăng tỷ lệ lựa chọn giữa các lớp lên 40–70% và truy xuất các ví dụ có độ đa dạng về nhận thức cao hơn. Ví dụ, trên tập dữ liệu APTOS, TACS thường ghép các trường hợp bệnh võng mạc tiểu đường nhẹ và nặng, cho phép mô hình so sánh mức độ nghiêm trọng của tổn thương; trên SUN397, nó truy xuất các cảnh trong môi trường tương phản để làm rõ các ranh giới chi tiết. Những phát hiện này chỉ ra rằng chính sách đã học nắm bắt được tính bổ sung phù hợp với nhiệm vụ hơn là sự dư thừa. LIPS cũng nói điều tương tự

Bảng 4. Loại bỏ các phương pháp xây dựng cặp ngữ cảnh. Hình ảnh ngữ cảnh không được cung cấp, được cung cấp dưới dạng hình ảnh trống, bản sao của hình ảnh truy vấn hoặc phiên bản nhiễu của hình ảnh truy vấn.

Context Image	Aircr. mAcc ↑	Cal101 mAcc ↑	Cal256 mAcc ↑	C10 Acc ↑	C100 Acc ↑	CUB Acc ↑	DTD Acc ↑	Food Acc ↑	Pets mAcc ↑	Cars Acc ↑	SUN Acc ↑	APTOS F ↑	Col. Acc ↑	DDSM AUC ↑	ISIC Rec ↑	Avg. - ↑
No context image	84.3	94.3	87.8	97.9	87.8	82.1	76.1	89.2	89.8	92.4	68.0	89.8	96.2	96.1	82.0	87.6
Blank Image	84.2	94.1	87.3	97.7	87.6	82.4	74.7	89.1	89.4	92.2	67.6	90.0	96.7	96.2	83.7	87.5
Duplicate Query	84.1	94.1	87.0	97.9	87.4	82.6	75.9	89.3	89.9	92.4	67.5	89.9	96.6	96.4	83.9	87.7
Noisy Query	84.4	94.4	87.2	97.6	88.1	82.6	75.6	89.3	89.6	92.5	67.8	89.8	96.8	96.5	84.2	87.8
Similar image (DINOv3)	85.1	94.7	87.3	97.8	88.4	81.4	75.4	89.9	90.3	93.0	69.2	90.4	97.0	96.1	84.5	88.0
TACS Context image	85.9	95.9	89.3	98.5	89.2	85.2	77.7	92.6	91.3	94.1	71.8	91.1	97.9	97.4	85.2	89.5

Bảng 5. Sự cắt bỏ trên các thành phần của TACS.

Method	Fine-Grained	Med Cls.
Frozen DINO Similarity Ret.	86.6	92.0
Differentiable selection (no policy)	86.7	92.1
Policy-based selection (no Gumbel-Softmax)	87.2	92.4
Full dual optimization (TACS)	88.3	92.9



Hình 3. Phân tích thống kê các cặp bối cảnh được chọn. So sánh tỷ lệ lựa chọn giữa các lớp và khoảng cách LPIPS trung bình cho các cặp được chọn theo các chiến lược truy xuất khác nhau. TACS luôn chọn tỷ lệ ứng viên đa lớp và đa dạng về mặt nhận thức (LPIPS cao hơn) cao hơn so với công cụ truy xuất cố định, đặc biệt là trên các bộ dữ liệu phức tạp như DTD và SUN397. Điều này chỉ ra rằng chính sách đã học ủng hộ các ví dụ bổ sung thay vì chỉ các ví dụ tương tự, cho phép lập luận theo ngữ cảnh phong phú hơn.

câu chuyện, trong đó trên tất cả các tập dữ liệu hình ảnh được truy xuất từ TACS hiển thị ít sự tương đồng về mặt hình ảnh với hình ảnh truy vấn hơn so với những hình ảnh được truy xuất theo các tính năng được huấn luyện trước DINO.

Trực quan hóa chất lượng. Hình 4 minh họa các ví dụ định tính so sánh truy xuất dựa trên sự tương đồng và truy xuất phù hợp với nhiệm vụ trong các lĩnh vực y tế và tự nhiên. Một mô hình nhất quán xuất hiện: mạng Bộ chọn và Nhiệm vụ phát triển các hành vi chú ý riêng biệt nhưng bổ sung cho nhau. Bộ chọn tập trung vào các mẫu cấu trúc hoặc ngữ cảnh rộng như cấu trúc liên kết mạch máu trong quét võng mạc, cấu trúc vú trong chụp nhũ ảnh hoặc bố cục hình học trong các cảnh, trong khi Mạng nhiệm vụ tinh chỉnh sự chú ý của nó đến các chi tiết phân biệt rõ ràng, chi tiết trong hình ảnh truy vấn. Trong các tập dữ liệu y tế, các ví dụ được truy xuất thường nêu bật những điểm tương phản có liên quan đến chẩn đoán, chẳng hạn như ranh giới khối hoặc bất thường về mạch máu giúp bộ phân loại xác định vị trí bệnh lý chính xác hơn.


In fine-grained recognition, TACS retrieves semantically related but visually contrasting images that clarify decision boundaries. For example, in SUN397, when the query depicts an aquarium, TACS retrieves a window façade—an image that shares planar reflections and glass textures yet exhibits the rigid framing and outdoor illumination absent in the query. This counterfactual pairing allows the model to reason contrastively, reinforcing its aquarium prediction by recognizing what distinguishing features are *missing*. Similar cases are observed on Caltech-101 and DTD as well. Notably, TACS also selects similar samples when needed, such as identifying the dollar object. Overall, these results suggest that TACS learns to retrieve complementary, helpful examples, enabling the system to reason through structural analogy and contrast adaptively instead of mere similarity.

5. Thảo luận

H1: Khái quát hóa giữa các nhiệm vụ và lĩnh vực. Trên 18 bộ dữ liệu bao gồm hình ảnh tự nhiên và y tế, TACS liên tục cải thiện hiệu suất trên tất cả các đường cơ sở, xác nhận tính tổng quát của nó. Lợi ích mạnh nhất xuất hiện ở các miền có sự mơ hồ cao trong nội bộ lớp và sự giám sát hạn chế, chẳng hạn như CUB-200, SUN397 và DDSM. Những kết quả này cho thấy rằng việc truy xuất phù hợp với nhiệm vụ không phải là miền cụ thể: cơ chế tương tự giúp mô hình phân biệt cảnh quan cũng có thể cải thiện độ chính xác chẩn đoán trong hình ảnh y tế. Điều này chứng tỏ rằng việc học *điều hữu ích* là một khuynh hướng quy nạp có thể chuyển giao, bổ sung cho các nhiệm vụ đa dạng.

H2: Lợi ích bắt nguồn từ việc truy hồi đã học được. Các nghiên cứu cắt bỏ xác nhận rằng những cải tiến phát sinh từ chính quá trình lựa chọn phù hợp với nhiệm vụ chứ không phải từ các thông số bổ sung hoặc tiếp xúc với dữ liệu. Cả hai con đường tối ưu hóa dựa trên chính sách và có thể phân biệt đều đóng góp những điểm mạnh bổ sung: con đường trước ổn định việc đào tạo sớm bằng cách hình thành các mối quan hệ tiện ích liên tục, trong khi con đường sau làm sắc nét các ranh giới quyết định riêng biệt thông qua phản hồi dựa trên phần thưởng. Cùng với nhau, các thành phần này cho phép TACS chọn các mẫu có ý nghĩa cải thiện độ chính xác ở phía sau—một khả năng mà các phương pháp dựa trên sự tương tự tĩnh còn thiếu.

H3: Lý luận theo ngữ cảnh có thể giải thích được. Hình dung về sự chú ý của bộ chọn và bộ phân loại (Hình 4) cho thấy một kiến thức đã học



Hình 4. Đối với mỗi ví dụ, chúng tôi hiển thị (1) hình ảnh truy vấn, (2) sự chú ý của trình phân loại TACS đối với hình ảnh truy vấn (cùng nhận được hình ảnh ngữ cảnh đã chọn), (3) sự chú ý của trình phân loại không có ngữ cảnh đối với cùng một hình ảnh, (4) hình ảnh ngữ cảnh được Bộ chọn chọn và (5) sự chú ý của Bộ chọn đối với hình ảnh đã chọn. TACS luôn tập trung phân loại vào nhiều vùng phân biệt đối xử hơn so với mô hình không có ngữ cảnh. Bộ chọn tham gia vào các cấu trúc tổng thể rộng lớn, thường chọn các hình ảnh bổ sung thay vì tương tự về mặt hình ảnh (ví dụ:., lấy một cây đàn piano để giúp phân biệt tai nghe), cho phép bộ phân loại tinh chỉnh các quyết định chi tiết thông qua các tín hiệu ngữ cảnh tương phản.

phân công lao động: Bộ chọn nhấn mạnh vào cấu trúc toàn cầu và các tín hiệu theo ngữ cảnh, trong khi mô hình Nhiệm vụ tập trung vào các khu vực có tính phân biệt đối xử rõ ràng. Trong một số trường hợp, TACS giải quyết sự mơ hồ bằng cách truy xuất các ví dụ giữa các lớp để làm rõ ranh giới quyết định—ví dụ: truy xuất hình ảnh cửa sổ khi phân loại bê cá, giúp mô hình nhận ra sự vắng mặt của khung cửa sổ và xác nhận nhân bê cá. Hành vi này gợi ý rằng TACS phát triển sự hiểu biết tiềm ẩn về cách sự tương phản theo ngữ cảnh nâng cao khả năng nhận biết, đưa ra một dạng cụ thể về khả năng diễn giải dựa trên lợi ích của nhiệm vụ thay vì sự tương đồng về mặt hình ảnh.

Ý nghĩa rộng hơn. Truy xuất phù hợp với nhiệm vụ điều chỉnh lại cách các mô hình phân biệt đối xử sử dụng dữ liệu theo ngữ cảnh. Thay vì coi việc truy xuất là một bước tiền xử lý, TACS tích hợp nó vào chính quá trình suy luận, cho phép mô hình xác định một cách linh hoạt thông tin nào sẽ cải thiện các quyết định của nó. Thông tin chi tiết này kết nối với các chủ đề rộng hơn như quản lý dữ liệu, học tập tích cực và lý luận trực quan, cho thấy rằng việc học cách chọn *các ví dụ hữu ích* có thể đóng vai trò là nguyên tắc thống nhất cho trí tuệ thị giác thích ứng.

Những hạn chế và công việc trong tương lai. Các hạn chế hiện tại bao gồm sự phụ thuộc vào một nhóm ứng viên cố định và việc sử dụng một mẫu được truy xuất duy nhất cho mỗi truy vấn. Việc mở rộng video và ra quyết định đa phương thức là những bước tiếp theo đầy hứa hẹn.

6. Kết luận

Chúng tôi đã giới thiệu Lựa chọn bối cảnh phù hợp với nhiệm vụ (TACS), một khuôn khổ cho phép các mô hình tầm nhìn phân biệt tìm hiểu những gì hữu ích. Bằng cách cùng nhau tối ưu hóa Mạng Bộ chọn và Mạng tác vụ thông qua mục tiêu chính sách-có thể phân biệt kết hợp, TACS chuyển đổi việc truy xuất ngữ cảnh từ phương pháp phỏng đoán tương tự tĩnh thành mô-đun suy luận phù hợp với nhiệm vụ. Các thử nghiệm trên 18 bộ dữ liệu cho thấy mức tăng nhất quán, đặc biệt là trong các môi trường có độ mơ hồ cao và hạn chế về dữ liệu, đồng thời các phân tích định tính cho thấy các chiến lược truy xuất bổ sung khác với các đường cơ sở lân cận gần nhất. Công việc này mở ra một hướng mới cho tầm nhìn tăng cường truy hỏi: sử dụng bối cảnh bên ngoài có chọn lọc như một cơ chế lý luận có thể học được thay vì một bước tiền xử lý. Công việc trong tương lai bao gồm mở rộng quy mô sang các nhóm lớn hơn và mở rộng khả năng truy xuất phù hợp với nhiệm vụ sang các quy trình suy luận tầm nhìn rộng hơn.

Lời cảm ơn. Chúng tôi xác nhận rằng công việc này được hỗ trợ một phần bởi Wallenberg AI, Chương trình phần mềm và hệ thống tự trị (WASP) do Quỹ Knut và Alice Wallenberg tài trợ. Việc tính toán được thực hiện nhờ tài nguyên Berzelius do Quỹ Knut và Alice Wallenberg tại Trung tâm Siêu máy tính Quốc gia và Cơ sở hạ tầng hàn lâm quốc gia về Siêu máy tính ở Thụy Điển (NAISS) cung cấp.

References

- [1] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katherine Millican, Malcolm Reynolds, et al. Flamingo: a visual language model for few-shot learning. *Advances in neural information processing systems*, 35:23716–23736, 2022. 5
- [2] Mona Alzahrani, Muhammad Usman, Saeed Anwar, and Tarek Helmy. Selective multi-view deep model for 3d object classification. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 728–736, 2024. 1
- [3] Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. Self-RAG: Learning to retrieve, generate, and critique through self-reflection. *arXiv preprint arXiv:2310.11511*, 2023. 1, 2, 3
- [4] Andreas Blattmann, Robin Rombach, Kaan Oktay, Jonas Müller, and Björn Ommer. Retrieval-augmented diffusion models. *Advances in Neural Information Processing Systems*, 35:15309–15324, 2022. 2
- [5] Daniel Bolya, Po-Yao Huang, Peize Sun, Jang Hyun Cho, Andrea Madotto, Chen Wei, Tengyu Ma, Jiale Zhi, Jathushan Rajasegaran, Hanoona Rasheed, Junke Wang, Marco Monteiro, Hu Xu, Shiyu Dong, Nikhila Ravi, Daniel Li, Piotr Dollár, and Christoph Feichtenhofer. Perception encoder: The best visual embeddings are not at the output of the network. *arXiv:2504.13181*, 2025. 1
- [6] Lukas Bossard, Matthieu Guillaumin, and Luc Van Gool. Food-101—mining discriminative components with random forests. In *European conference on computer vision*, pages 446–461. Springer, 2014. 5
- [7] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International conference on machine learning*, pages 1597–1607. Pmlr, 2020. 5
- [8] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, Sammy Mohamed, and Andrea Vedaldi. Describing textures in the wild. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3606–3613, 2014. 5
- [9] Noel CF Codella, David Gutman, M Emre Celebi, Brian Helba, Michael A Marchetti, Stephen W Dusza, Aadi Kalloo, Konstantinos Liopyris, Nabin Mishra, Harald Kittler, et al. Skin lesion analysis toward melanoma detection: A challenge at the 2017 international symposium on biomedical imaging (isbi), hosted by the international skin imaging collaboration (isic). In *2018 IEEE 15th international symposium on biomedical imaging (ISBI 2018)*, pages 168–172. IEEE, 2018. 5
- [10] Marc Combalia, Noel CF Codella, Veronica Rotemberg, Brian Helba, Veronica Vilaplana, Ofer Reiter, Cristina Carrera, Alicia Barreiro, Allan C Halpern, Susana Puig, et al. Bcn20000: Dermoscopic lesions in the wild. *arXiv preprint arXiv:1908.02288*, 2019. 5
- [11] Manuel Faysse, Hugues Sibille, Tony Wu, Bilel Omrani, Gautier Viaud, Céline Hudelot, and Pierre Colombo. Colpali: Efficient document retrieval with vision language models, 2024. 2
- [12] Li Fei-Fei, Rob Fergus, and Pietro Perona. Learning generative visual models from few training examples: An incremental bayesian approach tested on 101 object categories. In *2004 conference on computer vision and pattern recognition workshop*, pages 178–178. IEEE, 2004. 5
- [13] Jingsheng Gao, Linxu Li, Ke Ji, Weiyuan Li, Yixin Lian, yuzhuo fu, and Bin Dai. SmartRAG: Jointly learn RAG-related tasks from the environment feedback. In *The Thirteenth International Conference on Learning Representations*, 2025. 1, 2, 3
- [14] Gregory Griffin, Alex Holub, Pietro Perona, et al. Caltech-256 object category dataset. Technical report, Technical Report 7694, California Institute of Technology Pasadena, 2007. 5
- [15] Jingyu Guo, Christos Matsoukas, Fredrik Strand, and Kevin Smith. Random token fusion for multi-view medical diagnosis. In *Advancements In Medical Foundation Models: Explainability, Robustness, Security, and Beyond*, 2024. 1
- [16] Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat, and Mingwei Chang. Retrieval augmented language model pre-training. In *Proceedings of the 37th International Conference on Machine Learning*, pages 3929–3938. PMLR, 2020. 2
- [17] Yunzhong Hou, Stephen Gould, and Liang Zheng. Learning to select views for efficient multi-view understanding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 20135–20144, 2024. 1
- [18] Ziniu Hu, Ahmet Iscen, Chen Sun, Zirui Wang, Kai-Wei Chang, Yizhou Sun, Cordelia Schmid, David A Ross, and Alireza Fathi. Reveal: Retrieval-augmented visual-language pre-training with multi-source multimodal knowledge memory. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 23369–23379, 2023. 2, 3
- [19] Joana Palés Huix, Adithya Raju Ganeshan, Johan Fredin Haslum, Magnus Söderberg, Christos Matsoukas, and Kevin Smith. Are natural domain foundation models useful for medical image classification? In *Proceedings of the IEEE/CVF winter conference on applications of computer vision*, pages 7634–7643, 2024. 5
- [20] Gautier Izacard and Edouard Grave. Distilling knowledge from reader to retriever for question answering. In *International Conference on Learning Representations*, 2021. 2, 3
- [21] Gautier Izacard, Patrick Lewis, Maria Lomeli, Lucas Hosseini, Fabio Petroni, Timo Schick, Jane Dwivedi-Yu, Armand Joulin, Sebastian Riedel, and Edouard Grave. Atlas: Few-shot learning with retrieval augmented language models. *Journal of Machine Learning Research*, 24(251):1–43, 2023. 3
- [22] Eric Jang, Shixiang Gu, and Ben Poole. Categorical reparameterization with gumbel-softmax. In *5th International Conference on Learning Representations, ICLR 2017, Toulon, France, April 24-26, 2017, Conference Track Proceedings*. OpenReview.net, 2017. 3
- [23] Debesh Jha, Pia H Smedsrud, Michael A Riegler, Pål Halvorsen, Thomas De Lange, Dag Johansen, and Håvard D Johansen. Kvasir-seg: A segmented polyp dataset. In *In-*

- hội nghị quốc tế về mô hình hóa đa phương tiện, trang 451–462. Springer, 2019. 5
- [24] Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick SH Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, và Wen-tau Yih. Truy xuất đoạn văn đầy đặc để trả lời câu hỏi trong miền mở. Trong *EMNLP (1)*, trang 6769–6781, 2020. 1, 2 [25] Karthik, Maggie và Sohler Dane. Aptos 2019 phát hiện mù. <https://kaggle.com/competitions/aptos2019-blindness-Detection>, 2019. Kaggle. 5
- [26] Jakob Nikolas Kather, Cleo-Aron Weis, Francesco Bianconi, Susanne M Melchers, Lothar R Schad, Timo Gaiser, Alexander Marx, và Frank Gerrit Zöllner. Phân tích kết cấu đa lớp trong mô học ung thư đại trực tràng. *Báo cáo khoa học*, 6(1): 1–11, 2016. 5
- [27] Jonathan Krause, Michael Stark, Giả Đặng và Lý Phi Phi. Biểu diễn đối tượng 3D để phân loại chi tiết. Trong *Kỷ yếu của hội nghị quốc tế IEEE về hội thảo về thị giác máy tính*, trang 554–561, 2013. 5 [28] Alex Krizhevsky, Geoffrey Hinton, et al. Học nhiều lớp đặc điểm từ những hình ảnh nhỏ, 2009. 5
- [29] Rebecca Sawyer Lee, Francisco Gimenez, Assaf Hoogi, Kanae Kawai Miyake, Mía Gorovoy và Daniel L Rubin. Bộ dữ liệu chụp nhũ ảnh được tuyển chọn để sử dụng trong nghiên cứu chẩn đoán và phát hiện có sự hỗ trợ của máy tính. *Dữ liệu khoa học*, 4(1):1–9, 2017. 5
- [30] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. Thể hệ tăng cường truy xuất cho các nhiệm vụ NLP chuyên sâu về kiến thức. *Những tiến bộ trong hệ thống xử lý thông tin thần kinh*, 33:9459–9474, 2020. 1, 2
- [31] Xinze Li, Sen Mei, Zhenghao Liu, Yukun Yan, Shuo Wang, Shi Yu, Zheni Zeng, Hao Chen, Ge Yu, Zhiyuan Liu, et al. Rag-ddr: Tối ưu hóa thể hệ tăng cường truy xuất bằng cách sử dụng phần thưởng dữ liệu có thể phân biệt. *arXiv preprint arXiv:2410.13509*, 2024. 2, 3
- [32] Yiwei Li, Yikang Liu, Jiaqi Guo, Lin Zhao, Zheyuan Zhang, Xiao Chen, Boris Mailhe, Ankush Mukherjee, Terrence Chen và Shanhui Sun. Rau: Sự hiểu biết về giải phẫu dựa trên tham chiếu với các mô hình ngôn ngữ thị giác. *arXiv preprint arXiv:2509.22404*, 2025. 2
- [33] Long Lian, Yifan Ding, Yunhao Ge, Sifei Liu, Hanzi Mao, Boyi Li, Marco Pavone, Ming-Yu Liu, Trevor Darrell, Adam Yala, et al. Mô tả mọi thứ: Chú thích chi tiết về hình ảnh và video đã bản địa hóa. *arXiv bản in trước arXiv:2504.16072*, 2025. 5
- [34] Haotian Liu, Kilho Son, Jianwei Yang, Ce Liu, Jianfeng Gao, Yong Jae Lee và Chunyuan Li. Học các mô hình trực quan tùy chỉnh với kiến thức tăng cường truy xuất. Trong *Kỷ yếu của Hội nghị IEEE/CVF về Thị giác máy tính và Nhận dạng mẫu*, trang 15148–15158, 2023. 2 [35] Tian Liu, Huixin Zhang, Shubham Parashar và Shu Kong. Nhận dạng ít lần chụp thông qua tinh chỉnh tăng cường truy xuất theo giai đoạn. Trong *Kỷ yếu của Hội nghị về Thị giác Máy tính và Nhận dạng Mẫu*, trang 15086–15097, 2025. 2 [36] Alexander Long, Wei Yin, Thalaiyasingam Ajanthan, Vu Nguyen, Pulak Purkait, Ravi Garg, Alan Blair, Chunhua Shen và Anton Van den Hengel. Phân loại tăng cường truy xuất để nhận dạng hình ảnh đuôi dài. Trong *Kỷ yếu của hội nghị IEEE/CVF về thị giác máy tính và nhận dạng mẫu*, trang 6959–6969, 2022. 2
- [37] Ilya Loshchilov và Frank Hutter. Chính quy hóa giảm cân tách rời. *arXiv bản in trước arXiv:1711.05101*, 2017. 5 [38] Subhransu Maji, Esa Rahtu, Juho Kannala, Matthew Blaschko và Andrea Vedaldi. Phân loại trực quan chi tiết về máy bay. *arXiv preprint arXiv:1306.5151*, 2013. 5
- [39] Vishwesh Nath, Wenqi Li, Dong Yang, Andriy Myronenko, Mingxin Zheng, Yao Lu, Zhijian Liu, Hongxu Yin, Yee Man Law, Yu Cheng Tang, và những người khác. Vila-m3: Tăng cường mô hình ngôn ngữ thị giác với kiến thức chuyên môn y tế. Trong *Kỷ yếu của Hội nghị Nhận dạng Mẫu và Thị giác Máy tính*, trang 14788–14798, 2025. 1
- [40] Omkar M Parkhi, Andrea Vedaldi, Andrew Zisserman, và CV Jawahar. Mèo và chó. Trong *Hội nghị IEEE 2012 về thị giác máy tính và nhận dạng mẫu*, trang 3498–3505. IEEE, 2012. 5
- [41] René Ranftl, Alexey Bochkovskiy và Vladlen Koltun. Máy biến đổi tầm nhìn để dự đoán đầy đặc. Trong *Kỷ yếu hội nghị quốc tế IEEE/CVF về thị giác máy tính*, trang 12179–12188, 2021. 5
- [42] Zhengliang Shi, Lingyong Yan, Weiwei Sun, Yue Feng, Pengjie Ren, Xinyu Ma, Shuaiqiang Wang, Dawei Yin, Maarten de Rijke, và Zhaochun Ren. Tối ưu hóa tăng cường truy xuất trực tiếp: Phối hợp lựa chọn kiến thức và mô hình ngôn ngữ. *arXiv preprint arXiv:2505.03075*, 2025. 3
- [43] Hui Shuai, Lele Wu và Qingshan Liu. Biến áp hợp nhất thời gian và đa góc nhìn thích ứng để ước tính tư thế con người 3d. *Giao dịch của IEEE về Phân tích Mẫu và Trí thông minh Máy*, 45(4):4122–4135, 2022. 1
- [44] Oriane Siméoni, Huy V. Võ, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, Francisco Massa, Daniel Haziza, Luca Jianyuan, Wang, Wang Timothée Darcet, Théo Moutakanni, Leonel Sentana, Claire Roberts, Andrea Vedaldi, Jamie Tolan, John Brandt, Camille Couprie, Julien Mairal, Hervé Jégou, Patrick Batut và Piotr Bonowski. DINOv3, 2025. 1, 5 [45] Devendra Singh, Siva Reddy, Will Hamilton, Chris Dyer và Dani Yogatama. Đào tạo toàn diện về trình đọc và truy xuất nhiều tài liệu để trả lời câu hỏi trong miền mở. *Những tiến bộ trong Hệ thống xử lý thông tin thần kinh*, 34: 25968–25981, 2021. 2
- [46] Joes Staal, Michael D Abramoff, Meindert Niemeijer, Max A Viergever, và Bram Van Ginneken. Phân đoạn mạch dựa trên sườn trong hình ảnh màu của võng mạc. *Giao dịch của IEEE về hình ảnh y tế*, 23(4):501–509, 2004. 5 [47] Philipp Tschandl, Cliff Rosendahl và Harald Kittler. Bộ dữ liệu ham10000, một bộ sưu tập lớn các hình ảnh soi da đa nguồn về các tổn thương sắc tố da phổ biến. *Dữ liệu khoa học*, 5(1):1–9, 2018. 5
- [48] Catherine Wah, Steve Branson, Peter Welinder, Pietro Perona, và Serge Belongie. Bộ dữ liệu caltech-ucsd Birds-200-2011, 2011. 5

[49] Jianxiong Xiao, James Hays, Christ A Ehinger, Aude Oliva, và Antonio Torralba. Cơ sở dữ liệu mặt trời: Nhận dạng cảnh quy mô lớn từ tu viện đến sở thú. Trong *Hội nghị của Hiệp hội Máy tính IEEE năm 2010 về Thị giác Máy tính và Nhận dạng Mẫu*, trang 3485–3492. IEEE, 2010

[50] Shi Yu, Chaoyue Tang, Bokai Xu, Junbo Cui, Junhao Ran, Yukun Yan, Zhenghao Liu, Shuo Wang, Xu Han, Zhiyuan Liu, et al. Visrag: Thệ hệ tăng cường truy xuất dựa trên tầm nhìn trên các tài liệu đa phương thức. *arXiv preprint arXiv:2410.10594*, 2024. 2

[51] Lin Zhao, Xiao Chen, Eric Z Chen, Yikang Liu, Terence Chen và Shanhui Sun. Phân đoạn hình ảnh y tế bằng vài lần chụp được tăng cường truy xuất với các mô hình nền tảng. *Giao dịch IEEE trên Mạng thần kinh và Hệ thống học tập*, 2025. 2, 5

[52] Xu Zheng, Ziqiao Weng, Yuanhuiyi Lyu, Lutao Jiang, Hai-wei Xue, Bin Ren, Danda Paudel, Nicu Sebe, Luc Van Gool, và Xuming Hu. Truy xuất tăng cường thệ hệ và hiểu biết về tầm nhìn: Một cuộc khảo sát và triển vọng mới. *arXiv preprint arXiv:2503.18016*, 2025. 1, 2